

# MC920 Trabalho 1 - Filtragem de Imagens

182851 - Lucy Miyuki Miyagusiku Narita

17 de abril de 2019

## 1 Introdução

O objetivo deste trabalho é implementar alguns filtros nos domínios espacial e de frequências. Filtros permitem que sejam aplicados diversos efeitos em imagens, alterando os valores de intensidade dos pixels.

Juntamente desse relatório está sendo enviado um notebook *Jupyter* que contém o código e as imagens referentes ao projeto.

### 1.1 Filtragem no Domínio Espacial

O domínio espacial refere-se ao próprio plano da imagem, ou seja, ao conjunto de pixels que compõem uma imagem. [1]

O processo de filtragem neste domínio é normalmente feito através de matrizes denominadas *máscaras* que representam o peso do pixel em questão e de sua vizinhança. A máscara é então convolucionada com a imagem em que se queira aplicar o filtro.

### 1.2 Filtragem no Domínio de Frequência

Para trabalhar no domínio da frequência, aplicamos a transformada de Fourier na imagem. A expressão discretizada da transformada é dada por:

$$F[k] = \sum_{n=0}^{N-1} f[n] \exp\left(\frac{-i2\pi kn}{N}\right)$$

[2]

e sua inversa:

$$f[n] = \frac{1}{N} \sum_{k=0}^{N-1} F[k] \exp\left(\frac{i2\pi kn}{N}\right)$$

[2]

Para a aplicação do filtro, há uma relação de reciprocidade entre a convolução no domínio espacial e sua contrapartida no domínio da frequência:

$$\mathcal{F}(f(x, y)h(x, y)) \iff \mathcal{F}(f(x, y)) * \mathcal{F}(h(x, y))$$

[2]

e

$$\mathcal{F}(f(x, y) * h(x, y)) \iff \mathcal{F}(f(x, y))\mathcal{F}(h(x, y))$$

[2]

Portanto, executamos uma multiplicação termo a termo entre os elementos da matriz da transformada da imagem original com a matriz da transformada da máscara a ser aplicada.

## 2 Execução

O projeto foi desenvolvido em Python 2.7.15 e também foi testado com Python 3.6.7, utilizando os seguintes pacotes como dependências:

- Manipulação de dados
  - `numpy`
  - `opencv`
- Plotting
  - `matplotlib`
- Carregamento e download das imagens
  - `requests`
  - PIL (Pillow Imaging Library)

As imagens utilizadas se encontram na pasta `imgs/`. Por se tratar de um notebook, não há entrada de dados parametrizada.

## 3 Processo e Decisões Tomadas

### 3.1 O Processo de Convolução

A fórmula geral para o processo de convolução é dada por:

$$g(x, y) = \omega(x, y) * f(x, y) = \sum_{i=-a}^a \sum_{j=-b}^b \omega(i, j) f(x - i, y - j)$$

onde  $g(x, y)$  é o resultado (a imagem filtrada),  $f(x, y)$  é a entrada (a imagem original de dimensões  $(m, n)$ ),  $\omega$  é a matriz de convolução (máscara),  $a = \lfloor \frac{m}{2} \rfloor$  e  $b = \lfloor \frac{n}{2} \rfloor$

Para a aplicação das máscaras utilizamos a função `filter2D` do `openCV`, ao invés de criarmos nossa própria função de convolução, uma vez que estamos mais interessados na análise crítica do que na implementação da operação de convolução em si.

## 4 Resultados e Discussões

Os filtros foram aplicados à seguinte imagem:




Figura 1: Imagem original

## 4.1 Filtragem no Domínio Espacial

### 4.1.1 Filtro $h_1$




Figura 2: Aplicação do filtro  $h_1$

O filtro  $h_1$  é um filtro passa-alta. Por ser um filtro simples, com a soma dos pesos nula, ele realçará os pontos de alta frequência (**incluindo ruídos**), enquanto atenua as regiões com baixa variância.

### 4.1.2 Filtro $h_2$




Figura 3: Aplicação do filtro  $h_2$

O filtro  $h_2$  é um filtro passa-baixa de suavização Gaussiano (5x5) com  $\sigma = 1.0$  aproximado pela expansão binominal  $(a + b)^n = \sum_{k=0}^n \frac{n!}{k!(n-k)!} a^{n-k} b^k$ .

Média de tempo de aplicação do filtro em 5 amostras de mesmo tamanho:

CPU times: user 714  $\mu$ s, sys: 500  $\mu$ s, total: 1.21 ms

Wall time: 639  $\mu$ s

O Filtro  $h_2$  é separável e pode ser obtida a partir da convolução das seguintes máscaras unidimensionais:

$$h_2' = \frac{1}{16} \begin{bmatrix} 1 \\ 4 \\ 6 \\ 4 \\ 1 \end{bmatrix}$$

e

$$h_2'' = \frac{1}{16} [1 \quad 4 \quad 6 \quad 4 \quad 1]$$

A separação da máscara é interessante pois permite uma aplicação mais rápida (uma vez que faz menos operações) em 2 passos.




Figura 4: Aplicação dos filtros  $h_2'$  e  $h_2''$

Média de tempo de aplicação das máscaras unidimensionais em 5 amostras de mesmo tamanho:

CPU times: user 133  $\mu$ s, sys: 94  $\mu$ s, total: 227  $\mu$ s

Wall time: 235  $\mu$ s

### 4.1.3 Filtros $h_3$ e $h_4$




Figura 5: Aplicação do filtro  $h_3$




Figura 6: Aplicação do filtro  $h_4$




Figura 7: Aplicação dos filtros  $h_3$  e  $h_4$  combinados

Os filtros  $h_3$  e  $h_4$  são *Operadores de Sobel* ou *Filtros de Sobel* para detecção de bordas. O filtro  $h_3$  detecta as bordas verticais enquanto o filtro  $h_4$  detecta as bordas horizontais. A combinação dos dois ( $h_5$ ), portanto, compõe as bordas **horizontais e verticais** da imagem.

## 4.2 Filtragem no Domínio de Frequência

Para a filtragem de frequência, deveríamos utilizar um filtro Gaussiano.

O filtro Gaussiano é dado pela seguinte função de transferência:

$$H(u, v) = \exp\left(-\frac{D^2(u, v)}{2D_0^2}\right)$$

em que  $D_0$  é a frequência de corte e  $D(u, v)$  é a distância do pixel  $(u, v)$  até a componente de frequência zero (componente de maior frequência).




Figura 8: Imagem Original - Espectro de Frequência

A visualização do espectro de frequência da imagem original, sem nenhum filtro é vista na Figura 8. Como fizemos a translação da componente de frequência zero para o centro, as componentes de maior frequência, representados pelos pixels de maior intensidade, se encontrarão mais próximos ao centro.

Para esta filtragem, geramos 4 filtros com frequências de corte 10 (Figura 9), 20 (Figura 10), 40 (Figura 11) e 80 (Figura 12).

Como podemos observar, quanto **maior** o valor da frequência de corte, **menor** é a taxa de suavização da imagem, em comparação com o filtro Gaussiano no domínio espacial que, quanto **maior** o  $\sigma$ , **maior** a taxa de suavização.

## 5 Conclusão

Neste exercício pudemos aplicar e observar o efeito de alguns filtros utilizados no pré processamento de imagens, tanto no domínio espacial quanto no domínio da frequência.

Os resultados obtidos foram conforme o esperado:

- O realce das bordas com muito ruído do filtro  $h_1$ ;




Figura 9: Filtro Gaussiano com Frequência de Corte 10




Figura 10: Filtro Gaussiano com Frequência de Corte 20






Figura 11: Filtro Gaussiano com Frequência de Corte 40




Figura 12: Filtro Gaussiano com Frequência de Corte 80

- A suavização da imagem com o filtro  $h_2$ ;
- As bordas verticais, horizontais e o conjunto de bordas da imagem com os filtros  $h_3$ ,  $h_4$  e a combinação dos dois, respectivamente;
- A relação inversamente proporcional da frequência de corte com a taxa de suavização no filtro Gaussiano no domínio das frequências.

## Referências

- [1] Pedrini, H., *MC920 Introdução ao Processamento Digital de Imagens - Realce*, (Universidade Estadual de Campinas, UNICAMP. 2019). [Online] available at [http://www.ic.unicamp.br/helio/disciplinas/MC920/aula\\_realce.pdf](http://www.ic.unicamp.br/helio/disciplinas/MC920/aula_realce.pdf)
- [2] Pedrini, H., *MC920 Introdução ao Processamento Digital de Imagens - Domínio de Frequência*, (Universidade Estadual de Campinas, UNICAMP. 2019). [Online] available at [http://www.ic.unicamp.br/helio/disciplinas/MC920/aula\\_dominio\\_frequencia.pdf](http://www.ic.unicamp.br/helio/disciplinas/MC920/aula_dominio_frequencia.pdf)